


Graph-RAG auf dem Smartphone

Kann ein kuratierter Wissensgraph kleinen lokalen Sprachmodellen bei Multi-Hop-Fragen helfen?



Wie ich von der Idee zum Experiment kam

1 · Meine Ausgangsfrage

Wie kann ein kleines Sprachmodell auf meinem Smartphone verlässlicher mit lokalem Wissen arbeiten?



2 · Iterativer Aufbau

Ich habe Anforderungen formuliert, Varianten verglichen und das Projekt Schritt für Schritt mit Claude und ChatGPT im Chat weiterentwickelt.



3 · Meine Kontrolle

Ich habe Entscheidungen getroffen, den Code getestet, Inhalte geprüft und übernehme die Verantwortung für Methode und Ergebnis.

Idee → Dialogische Entwürfe → eigene Auswahl und Prüfung → Artefakt → Experiment

Lokal ist privat – aber Wissen bleibt knapp

On-Device-LLMs

- lokale Inferenz ohne eigenes Backend
- nach dem Modelldownload offline nutzbar
- private Daten bleiben auf dem Gerät
- kleine Modelle passen auf mobile Hardware

Das Wissensproblem

- lückenhaftes parametrisches Faktenwissen
- plausible, aber falsche Antworten
- begrenztes Kontext- und Speicherbudget
- Multi-Hop-Fragen verlangen mehrere Fakten

RAG lädt relevantes Wissen zur Laufzeit nach.

Zwei Retrieval-Pipelines im Vergleich

Vektor-RAG

Semantische Ähnlichkeitssuche über isolierte Kurztexte.

Faire Baseline: mehrsprachige dichte Embeddings, Top-k = 4.

Graph-RAG

Traversal über einen kuratierten, typisierten Wissensgraphen.

Kontext: relevante Beziehungstripel plus dieselben Kurztexte.

Wichtig: Der Messgraph wurde manuell kuratiert und eingefroren. Ich teste keine automatische Graphgewinnung aus rohen Wikipedia-Links.

Wann hilft explizite Struktur?

Verbessert Retrieval über einen kuratierten, typisierten Wissensgraphen die Antwortqualität kleiner On-Device-LLMs gegenüber Vektor-RAG und einer kontextfreien Baseline – besonders bei Multi-Hop-Fragen und zu welchen Ressourcenkosten?

H1 · RAG hilft

Beide RAG-Verfahren sollten die kontextfreie Baseline übertreffen.

H2/H3 · Hop-Tiefe

Bei einfachen Fragen ähnlich; erwarteter Graph-Vorteil bei 2–3 Hops.

H4/H5 · Trade-off

Weniger Konfabulation, aber mehr Kontext und höhere Kosten möglich.

Korpus, Fragen und Bedingungen

75 Entitäten

165 typisierte Kanten

5 Communities

40 Fragen

Kernbedingungen

B0 · ohne Kontext
B1 · Vektor-RAG
B2 · Graph-RAG

Strata

10 Einzeldokument/Direkt
14 echte 2-Hop
8 echte 3-Hop
4 Vergleich · 4 unbeantwortbar

Zusatzbedingungen

B1b · gleiches Kontextbudget
B3 · Graph + Vektor

Kontrolle und Exploration

Domäne: Deutscher Idealismus · Wikipedia-basierte Inhalte · manuell geprüfte, eingefrorene Repräsentation

So halte ich Reihenfolge und Laufzeit fair

01

Gleicher Prompt

Modell, Temperatur und Antwortlimit bleiben konstant.

02

Gegenbalanciert

Fragen seeded gemischt; Bedingungen zyklisch rotiert.

03

3 Wiederholungen

Jeder Lauf bleibt mit Run-ID und Seed erhalten.

04

Echte E2E-Zeit

Retrieval und Generierung werden getrennt und gemeinsam gemessen.

40 Fragen × 3 Kernbedingungen × 2 Modelle × 3 Wiederholungen = 720 Kern-Trials

Mehr als nur ein Gewinner

Antwortqualität

- verblindete Doppelbewertung
- korrekt / teilweise / falsch / Enthaltung
- Cohens κ
- Halluzinations- und Enthaltungsrate

Retrieval-Diagnose


- Evidenz-Recall
- Evidenz-Präzision
- Goldpfad vollständig?
- Retrieval- oder Generierungsfehler?

Ressourcen

- End-to-End-Latenz
- Retrievalzeit
- Generierungszeit
- Kontext- und Modellgröße

Primärvergleich: Graph-RAG vs. Vektor-RAG auf Multi-Hop-Fragen · Effektstärke + 95%-Konfidenzintervall

Graph-RAG Lab ist mein Messinstrument



Für die Live-Demo

1. Dieselbe Frage in B0, B1 und B2
2. Retrieval-Kontext und Subgraph öffnen
3. Messwerte vergleichen
4. Rohdaten exportieren

Grenzen und Transparenz

Grenzen

- eine Domäne und eine Sprache
- zwei kleine Modelle, 40 Fragen
- kuratierter statt automatisch erzeugter Graph
- Pipelinevergleich: Auswahl und Darstellungsform ändern sich
- explorativer Nachweis, kein universeller Benchmark

Mein KI-Einsatz

Ich nutzte Claude und ChatGPT ausschließlich dialogisch. Die Modelle erzeugten umfangreiche Code- und Textvorschläge. Ich gab Ziele vor, wählte aus, testete, prüfte und dokumentiere die verbleibenden Unsicherheiten.

Nächster Schritt: Hauptläufe → verblindete Bewertung → vollständige Veröffentlichung auch von Null- oder Negativbefunden