


Graph-RAG auf dem Smartphone

Hilft explizite Struktur kleinen lokalen
Sprachmodellen bei Multi-Hop-Fragen?

Sinan Yavuz Adigüzel · TU Dortmund



Privat heisst nicht allwissend.

PRIVAT

klein · lokal · nach dem Download offline

LÜCKENHAFT

Faktenwissen fehlt. Antworten können plausibel klingen und dennoch falsch sein.

**Die zentrale Frage lautet deshalb nicht: Wie groß ist das Modell? Sondern:
Welches Wissen erhält es im richtigen Moment?**

RAG erweitert Modellwissen.

PARAMETRISCHES WISSEN

Was das Modell
bereits in seinen
Gewichten gelernt
hat.

+ Kontext



RETRIEVAL-AUGMENTED GENERATION

Relevantes,
überprüfbares
Wissen wird für
eine konkrete
Frage
bereitgestellt.

Meine Arbeit prüft, ob die Form dieses Kontexts bei mehrstufigen Fragen einen Unterschied macht.

Graph-RAG macht Beziehungen sichtbar.

Vektor-RAG

[Hegel]
[Berlin]
[Schelling]

relevante Schnipsel – aber getrennt



Graph-RAG



Die Kette bleibt im Kontext sichtbar.

Das ist die Multi-Hop-Hypothese: Nicht mehr Text allein, sondern besser verbundene Evidenz.

Wann lohnt sich ein Wissensgraph?

Verbessert Graph-RAG auf einem kuratierten, typisierten Wissensgraphen die Antwortqualität kleiner On-Device-LLMs gegenüber Vektor-RAG und einer kontextfreien Baseline?

H1 RAG schlägt die Baseline · H2 bei einfachen Fragen annähernd gleich · H3 Graph-RAG profitiert bei 2–3 Hops

H4 bessere Enthaltung möglich · H5 mehr Kontext und höhere End-to-End-Kosten erwartet

Ein kleines, kontrolliertes Wissensuniversum.

75

Knoten

165 typisierte Beziehungen

40

Fragen

10 Direkt · 14 Zwei-Hop · 8 Drei-Hop

Kernvergleich


B0 kein Kontext

B1 Vektor-RAG

B2 Graph-RAG

Domäne: Deutscher Idealismus · Wikipedia-basierte Inhalte · manuell kuratierter und eingefrorener
Messgraph

Reihenfolge darf nicht verzerren.



40 Fragen × 3 Bedingungen × 2 Modelle × 3 Wiederholungen = 720 Kern-Trials

Ein Ergebnis muss erklärbar sein.

Antworten

Korrekt? Teilweise?
Enthaltung? Verblindete
Doppelbewertung.

Evidenz


War der Goldpfad überhaupt
im Kontext – oder scheiterte
das Retrieval?

Ressourcen

p50/p95 der End-to-End-Zeit,
Retrievalzeit und
Kontextgröße.

So kann ein Nullbefund genauso aufschlussreich sein wie ein Graph-RAG-Vorteil.

Die App macht den Vergleich messbar.



Kein eigenes Backend: Messdaten, Nutzerwissen und Modellinferenz bleiben auf dem Gerät.

Faire Messung ist mehr als Code.

1 · Reproduzierbarkeit

Wikipedia ändert sich. Deshalb habe ich einen kuratierten Messgraphen eingefroren.

2 · Faire Bedingungen


Graph-Kontexte können länger sein. Budgetkontrolle, gleiche Prompts und Rotation reduzieren Verzerrungen.

3 · Mobile Laufzeit

WebGPU, Modell- und Embedding-Downloads, Wärme und Cache-Zustände können Messungen beeinflussen.

Weitere Prüfaufgabe vor dem Hauptlauf: Fakten, Goldpfade und Hop-Tiefen des Katalogs einzeln gegen den Korpus kontrollieren.

Der Weg zur Antwort bleibt sichtbar.



Die App ist nicht nur eine Demo. Sie ist das Messinstrument für einen transparenten Vergleich.

Graph-RAG ist nicht einfach „besser“.

Sondern wann explizite Struktur ihren
Preis wert ist.

Ich dokumentiere auch Null- und Negativbefunde – sowie meinen iterativen KI-Einsatz mit Claude und ChatGPT – vollständig im Transparenz-Bericht.

Nächster Schritt: Messläufe · Bewertung · nachvollziehbare Ergebnisse

Erst prüfen, dann behaupten.

1 Messstand einfrieren

Commit, Gerät, Browser, Modelle, Seeds und Cache-Zustand dokumentieren.

2 Korpus kontrollieren

Alle Goldpfade, Hop-Tiefen und unbeantwortbaren Fragen gegen den Korpus prüfen.

3 Pipeline prüfen

Zeitmessung, Export und Verblindung zuerst technisch validieren.

Demo-Ausgaben sind kein Ergebnis. Erst exportierte und doppelt bewertete WebLLM-Läufe dürfen Hypothesen bestätigen oder widerlegen.

Quellen und Grundlagen.

[1] Lewis et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS.

[2] Edge et al. (2024). From Local to Global: A Graph RAG Approach to Query-Focused Summarization.

[3] Gutiérrez et al. (2024). HippoRAG. NeurIPS.

[4] Yang et al. (2018). HotpotQA. EMNLP.

[5] MLC-Team (2024). WebLLM: High-Performance In-Browser LLM Inference.

Korpusgrundlage: ausgewählte deutschsprachige Wikipedia-Artikel; konkrete Artikelversionen und Attribution werden im Transparenz-Bericht dokumentiert.

Wo ich KI verwendet habe

Claude und ChatGPT im Chat

- Ideenschärfung und Forschungsfrage
- Entwürfe für Code und UI
- Korpus- und Fragenentwürfe
- Struktur und Rohfassungen der Texte
- Präsentationsentwurf und Überarbeitung

Meine Verantwortung

Ich habe Ziele und Anforderungen vorgegeben, Varianten ausgewählt, Inhalte geprüft, Tests angestoßen und verantwortete Methode, Code, Quellen und Schlussfolgerungen.

Alle übernommenen Fakten und Quellen werden vor der Abgabe nochmals einzeln überprüft.